Agente que opera sistemas sin API: diseño

Frontier Bogotá 2026 · Reto 1 · Diseño del equipo

1. Problema

Convertir una petición en lenguaje natural en **exactamente** el resultado correcto dentro de una app de gestión que el agente nunca ha visto, usando solo píxeles, mouse y teclado por VNC, en menos de 5 minutos. "Correcto" significa que cambian los registros esperados y nada más: sin ediciones de más, sin duplicados, con un estado final honesto (`fallida` si la tarea es ambigua, imposible o peligrosa) y un resumen que el evaluador pueda leer. Lo difícil es **generalizar a interfaces desconocidas y saber cuándo detenerse**.

2. Supuestos

1. Las apps de evaluación se acceden igual que la de práctica (VNC, 1280×800) y son apps de gestión típicas: menús, listas, búsqueda y filtros, formularios, modales, confirmaciones, exportes.
2. La pantalla es la única fuente de verdad. No hay DOM, ni API, ni red desde la app.
3. "Hoy" es la fecha que muestra la app, no el reloj del servidor.
4. No sabemos cuántas tareas tiene el set oculto, así que el costo por tarea debe quedar muy por debajo de la reserva de US$5 (meta ≤ US$0,10).
5. La interfaz puede cambiar durante el día, así que no se programa nada específico de una app.

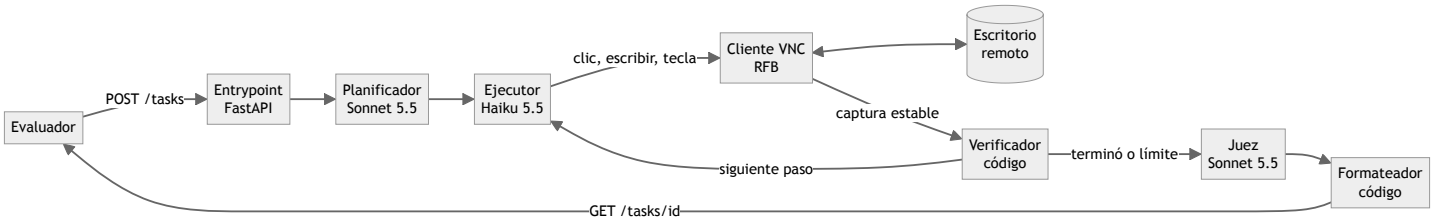
3. Casos difíciles y cómo los manejamos

Caso	Manejo
Entidad ambigua (dos "Ana Torres")	No modificar. Reportar `fallida` nombrando los datos que las distinguen (códigos, documentos)
Petición imposible o peligrosa	`fallida` con la razón. Se rechazan acciones destructivas que la tarea no pide
Preguntas (conteos, totales)	Usar los filtros y totales de la app; `respuesta: <número primero>` ; dos datos separados por `;`
Duplicados	Buscar antes de crear; nunca reenviar un formulario sin revisar la lista
Búsqueda literal (tildes) y listas paginadas	Probar variantes y recorrer páginas o filtrar antes de concluir "no existe" o de contar
Repintado lento, clics rápidos ignorados, texto que se concatena	Esperar pantalla estable (< 80 px en 0,6 s; medido ~1,5 s), clic de 150 ms, seleccionar todo antes de escribir
Se acaba el tiempo	Corte a los 4:30, reporte y no volver a tocar el escritorio

4. Fuera de alcance (y por qué)

Memoria persistente por app (queda vieja si la interfaz cambia; una memoria equivocada es peor que ninguna) · flujos entre varias apps · CAPTCHAs · ajustar un modelo (no hay datos que generalicen).

5. Arquitectura



El código se encarga de todo lo que debe ser exacto; los modelos, de lo que requiere juicio. El **Planificador** lee la tarea y la primera pantalla, y marca ambigüedad o peligro. El **Ejecutor** propone una acción por pantalla. El **Verificador** comprueba que la acción cambió la pantalla y aplica los límites. El **Juez** ve la pantalla final y el registro de acciones y decide `terminada` o `fallida` . El **Formateador** garantiza el formato del evaluador y borra secretos.

6. Decisiones

Decisión	Alternativa descartada	Por qué
Un modelo de visión lee capturas crudas	OCR + modelo solo de texto	El OCR pierde la disposición (qué etiqueta es de qué campo, íconos, casillas). Queda como pista si dominan los errores de lectura
Haiku 5.5 ejecuta cada paso (est. 25 pasos: ~US$0,06 por tarea con el juez, ~83 tareas con US$5)	Sonnet 5.5 como ejecutor (~US$0,31 por tarea, ~16 tareas con US$5)	Sonnet cuesta ~20 veces más y es más lento por paso: caben menos pasos en 5 min. Lo decide un bake-off medido
Sonnet solo donde hay juicio (plan, veredicto, escalamiento)	Un modelo barato para todo	El falso éxito y los rechazos equivocados son los errores más caros; dos llamadas fuertes son un seguro barato
El modelo propone, el código verifica	Creerle al reporte del modelo	El evaluador castiga el falso éxito; comparar pantallas y los límites atrapan fallas silenciosas
Cliente RFB propio sobre websocket	Navegador sin cabeza con noVNC	Menos capas y control exacto del tiempo de cada clic. noVNC queda de respaldo
Exploración nueva en cada tarea	Memoria persistente por app	Resiste cambios de interfaz; la exactitud pesa más que la velocidad
Railway, siempre encendido (Docker)	Portátil + túnel	El contrato exige disponibilidad hasta el demo day

7. Cómo medimos (antes de construir)

- **Un comando** `uv run python -m evals.run` resetea el escritorio, envía cada caso a nuestro entrypoint, llama `/__check` , revisa `estado` y el formato del resumen, y muestra tasa de éxito, costo por tarea, latencia y tipo de falla.
- **Casos:** los 5 entregados + ~15 propios (redacciones distintas y tareas nuevas de cada tipo: crear, editar, preguntar, exportar, ambigua, imposible, destructiva, fechas relativas, dos datos).
- **Generalización:** una **app de holdout** de otro dominio y otra disposición que el agente nunca ve mientras se ajusta, más un chequeo que falla si aparecen nombres de la app de práctica en el código o los prompts del agente.
- **Metas:** ≥ 80% en el set propio, ≥ 60% en el holdout, 0 acciones destructivas, ≤ US$0,10 y p95 < 4 min por tarea. Las 3 corridas del set oculto son hitos: esqueleto, después del incidente y final.

8. Riesgos y monitoreo

Riesgo	Detección	Respuesta
La interfaz cambia (15:30)	Alarmas "sin efecto" y "atascado"; eval base 15:00 y nueva corrida	El diff por caso muestra qué se rompió; se arregla y se documenta
Clics errados del modelo pequeño	Acciones repetidas sin efecto	Escalar ese paso a Sonnet después de 2 fallas
Sobrecosto	Costo registrado por llamada	Tope de costo por tarea; detenerse y reportar